

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Исследовательский проект на тему:

Семантические IDs в рекомендательных системах

Выполнил студент:

группы #БПМИ223, 4 курса

Сидоров Александр Михайлович

Принял руководитель ВКР:

Лукьяненко Никита Сергеевич

Научный сотрудник

Факультет компьютерных наук НИУ ВШЭ

Соруководитель:

Лапинин Олег Андреевич

Ведущий исследователь-разработчик

АО "Т-Банк"

Содержание

1	Введение	5
2	Обзор литературы	6
2.1	Рекомендательные системы	6
2.1.1	Коллаборативная фильтрация	6
2.1.2	Последовательные рекомендательные модели	6
2.2	Векторное квантование и дискретные представления	7
2.2.1	VQ-VAE	7
2.2.2	RQ	8
2.2.3	Residual K-means	8
2.3	Генеративные рекомендательные системы	9
2.3.1	Рекомендации как задача обработки текста	9
2.3.2	TIGER: генеративный поиск с семантическими идентификаторами . .	9
2.3.3	Обобщение семантических идентификаторов в задачах ранжирования .	9
2.4	Единый фреймворк GRID	10
2.5	Метрики оценки в рекомендательных системах	10
2.5.1	Extrinsic метрики	10
2.5.2	Intrinsic метрики семантических идентификаторов	11
2.6	Выводы по главе	11
3	Теоретические основы	13
3.1	Постановка задачи	13
3.2	Семантические идентификаторы	13
3.2.1	Определение	13
3.2.2	Ключевые свойства	14
3.3	Методы квантования	14
3.3.1	Векторное квантование (VQ-VAE)	14
3.3.2	Остаточное квантование (RQ)	15
3.3.3	RQ-VAE	15
3.3.4	Остаточный метод К-средних (RK-Means)	15
3.3.5	Остаточная векторная квантизация (RVQ)	16
3.4	Генеративная рекомендательная модель	16
3.5	Метрики качества	17

3.5.1	Extrinsic метрики рекомендаций	17
3.5.2	Intrinsic метрики семантических идентификаторов	17
4	Методология	22
4.1	Датасет	22
4.2	Протокол оценки	22
4.3	Рекомендательная модель	22
4.4	Методы квантования	22
4.5	Структура экспериментов	23
4.6	Кодирование периодичности взаимодействий	23
5	Результаты экспериментов	25
5.1	Группа А: сравнение методов квантования	25
5.2	Группа В: глубина кодового дерева L	26
5.3	Группа С: ширина кодбука W	28
5.4	Группа D: кодирование периодичности взаимодействий	29
5.5	Корреляционный анализ intrinsic и extrinsic метрик	30
5.5.1	Существование монотонной связи	30
5.5.2	Наилучшие предикторы extrinsic-качества	31
6	Заключение	32
6.1	Основные результаты	32
6.2	Практические рекомендации	33
6.3	Ограничения и направления дальнейших исследований	34
	Список литературы	35
	Приложение	37

Аннотация

Генеративные рекомендательные системы - молодая область, где рекомендации пользователям генерируются примерно так же, как это происходит при работе ChatGPT при генерации текста. Они активно развиваются в академических статьях, но довольно слабо применяются в промышленных приложениях. В этом проекте предлагается ознакомиться с самыми свежими наработками в области генеративных рекомендательных систем, воспроизвести и завалидировать часть результатов и предложить возможные улучшения/адаптацию под реальные промышленные проекты.

Тема довольно амбициозная в плане того, что генеративные модели теоретически могут заменить общепринятый двухуровневый пайплайн в рекомендациях (который используется в большинстве бигтех компаниях).

Ключевые слова

Глубинное обучение, машинное обучение, рекомендательные системы, генеративные модели

1 Введение

Рекомендательные системы являются одним из ключевых инструментов современных цифровых платформ, обеспечивая персонализированный доступ пользователей к релевантному контенту в условиях информационной перегрузки. Традиционные подходы к рекомендациям, основанные на коллаборативной фильтрации и матричном разложении, оперируют числовыми идентификаторами айтемов — произвольными целочисленными индексами, не несущими семантической информации о самих объектах. В последние годы в области рекомендательных систем наметилась принципиально новая парадигма — генеративный retrieval (generative retrieval), при которой модель не выбирает айтем из фиксированного множества кандидатов, а генерирует его идентификатор авторегрессивно, токен за токеном. Данный подход был реализован в работах TIGER [10] и Better Generalization with Semantic IDs [14]. Центральной концепцией этой парадигмы являются семантические идентификаторы (Semantic IDs, S-IDs) — дискретные иерархические коды, которые, в отличие от произвольных числовых индексов, кодируют семантическую близость между айтемами.

Цель настоящей работы — систематическое исследование свойств семантических идентификаторов в рекомендательных системах, включающее: (1) анализ и систематизацию метрик качества для оценки S-IDs; (2) сравнительный анализ актуальных методов построения семантических идентификаторов; (3) исследование влияния ключевых параметров S-IDs на качество рекомендаций. Объектом исследования являются методы построения дискретных семантических идентификаторов для айтемов в рекомендательных системах. Предметом исследования являются свойства семантических идентификаторов: их метрики качества, сравнительные характеристики и чувствительность к параметрам. Для достижения поставленной цели решаются следующие задачи:

Провести обзор и систематизацию существующих методов построения семантических идентификаторов. Разработать и обосновать систему метрик для оценки качества S-IDs. Реализовать экспериментальный стенд на датасете Amazon Reviews Beauty. Провести сравнительный эксперимент и ablation study по ключевым параметрам RQ-VAE. Сформулировать практические рекомендации по выбору метода и параметров S-IDs.

Работа построена следующим образом: в Главе 2 представлен обзор литературы; в Главе 3 изложены теоретические основы; в Главах 4 и 5 описаны методика, эксперименты и результаты; Заключение содержит выводы и направления дальнейших исследований.

2 Обзор литературы

В данной главе представлен систематический обзор научных работ по трём взаимосвязанным направлениям: рекомендательные системы и задача последовательного предсказания предпочтений пользователей, методы векторного квантования и дискретного представления данных, а также генеративные рекомендательные модели на основе семантических идентификаторов.

2.1 Рекомендательные системы

Рекомендательные системы решают задачу предсказания релевантных объектов (товаров, фильмов, новостей и др.) для конкретного пользователя на основе истории его взаимодействий и контекстных признаков [12]. За последние два десятилетия в этой области сложились два основных парадигматических подхода: коллаборативная фильтрация и методы на основе контентных признаков.

2.1.1 Коллаборативная фильтрация

Коллаборативная фильтрация основана на гипотезе, что пользователи со схожей историей взаимодействий в прошлом будут демонстрировать схожие предпочтения в будущем. Классические методы матричной факторизации, в частности SVD и ALS, раскладывают матрицу взаимодействий пользователь–объект на произведение двух матриц скрытых представлений и показали высокую эффективность на задачах прогнозирования оценок.

С развитием глубокого обучения матричная факторизация была обобщена до нейросетевых архитектур. Модель NeuMF [4] объединяет линейные и нелинейные взаимодействия эмбедингов пользователей и объектов. Подходы на основе графовых нейронных сетей, в частности LightGCN [3], явно моделируют структуру двудольного графа взаимодействий, распространяя информацию по рёбрам и достигая высокого качества за счёт простоты архитектуры. Тем не менее классические методы коллаборативной фильтрации испытывают затруднения в сценариях холодного старта и при работе с длиннохвостым распределением объектов [13].

2.1.2 Последовательные рекомендательные модели

В большинстве реальных систем задача рекомендации носит последовательный характер: пользователь взаимодействует с объектами в определённом порядке, и следующее

действие зависит от предыдущих. Это мотивирует разработку моделей, явно учитывающих временную динамику взаимодействий.

Ранние работы применяли марковские цепи для моделирования переходов между объектами [11]. Рекуррентные нейронные сети, в особенности архитектуры на базе LSTM и GRU, позволили захватывать долгосрочные зависимости в последовательностях [5]. Принципиальный прорыв в области произошёл с появлением модели SASRec [7], в которой для моделирования последовательностей взаимодействий используется механизм самовнимания (self-attention). SASRec демонстрирует конкурентоспособное качество при значительно меньших вычислительных затратах по сравнению с рекуррентными архитектурами и по сей день остаётся широко используемым базовым методом в исследованиях последовательных рекомендаций.

Несмотря на успехи, идентификаторы объектов в описанных подходах представляют собой произвольные целочисленные индексы, не несущие семантической информации. Эмбеддинги, соответствующие этим индексам, обучаются с нуля на данных взаимодействий и не используют контентные признаки объектов. Данное ограничение стало одной из ключевых мотиваций для разработки семантических идентификаторов.

2.2 Векторное квантование и дискретные представления

Для перехода от непрерывных представлений объектов к дискретным токенам, пригодным для авторегрессионного декодирования, применяются методы векторного квантования.

2.2.1 VQ-VAE

Базовым блоком для большинства современных методов квантования в рекомендательных системах является вариационный автокодировщик с векторным квантованием (VQ-VAE) [9]. В VQ-VAE кодировщик отображает входной объект в непрерывный латентный вектор $z_e \in \mathbb{R}^d$, который затем заменяется ближайшим вектором из обучаемого кодабука $\mathcal{E} = \{e_k\}_{k=1}^K$:

$$z_q = \arg \min_{e_k \in \mathcal{E}} \|z_e - e_k\|_2. \quad (1)$$

Обучение производится минимизацией суммы потерь реконструкции и потерь квантования с операцией остановки градиента (straight-through estimator) для передачи градиентов через недифференцируемую операцию $\arg \min$. Модель VQ-VAE показала высокую эффек-

тивность в задачах генерации изображений и аудио [9, 15] и послужила основой для рекомендательных применений.

2.2.2 RQ

Ключевым ограничением одноуровневого VQ-VAE является то, что один дискретный токен не может обеспечить достаточного разрешения для разнообразных каталогов объектов. Остаточное квантование (Residual Quantization, RQ) устраняет этот недостаток путём последовательного применения L уровней квантования. На каждом уровне l квантуется остаток r_l от предыдущего уровня:

$$r_0 = h, \quad c_l = \arg \min_k \|r_{l-1} - e_k^{(l)}\|_2, \quad r_l = r_{l-1} - e_{c_l}^{(l)}, \quad (2)$$

где $h \in \mathbb{R}^d$ — исходный эмбединг объекта, $e_k^{(l)}$ — k -й вектор кодбука уровня l . Результатом является кортеж кодов $(c_1, c_2, \dots, c_L)$, который и является семантическим идентификатором объекта.

2.2.3 Residual K-means

В работе One-Rec [1] предлагается использовать Residual K-means в качестве механизма дискретизации представлений. В отличие от классического k-means, где вектор h аппроксимируется одним центроидом, Residual K-means строит последовательное разложение: на каждом шаге к текущему остатку применяется отдельный k-means, обученный на ошибке предыдущего приближения. Таким образом, представление формируется как сумма выбранных центроидов из нескольких кодбуков.

Формально, на шаге t вычисляется резидуал $r^{(t)} = r^{(t-1)} - c^{(t-1)}$, где $c^{(t-1)}$ — центроид, выбранный на предыдущем шаге, а начальное значение $r^{(0)} = h$. Затем для каждого $r^{(t)}$ выбирается ближайший центроид $c^{(t)}$ из соответствующего кодбука. Итоговое приближение задаётся суммой $\sum_{t=1}^T c^{(t)}$.

Такой подход позволяет существенно повысить выразительность дискретного представления при фиксированном размере кодбуков, поскольку каждая итерация уточняет ошибку предыдущей аппроксимации. В контексте рекомендательных систем это даёт более точное кодирование эмбедингов пользователей и объектов по сравнению с одношаговыми методами квантования.

2.3 Генеративные рекомендательные системы

2.3.1 Рекомендации как задача обработки текста

Ранние работы по применению генеративных моделей к задаче рекомендации формулировали её как задачу условной генерации текста. Модель P5 [2] использует предобученную модель T5 и унифицирует задачи рекомендации, объяснения и диалога в едином текстовом формате. Объекты при этом идентифицируются своими текстовыми атрибутами или числовыми идентификаторами, преобразованными в строки. Хотя такой подход демонстрирует возможности обобщения, он страдает от неэффективности представления целочисленных идентификаторов в текстовом пространстве и сложности интеграции коллаборативного сигнала.

2.3.2 TIGER: генеративный поиск с семантическими идентификаторами

Принципиальный вклад в область внесла работа, в которой предложена модель TIGER [10]. TIGER вводит понятие семантического идентификатора объекта как кортежа дискретных кодов, полученных путём обучения RQ-VAE на текстовых эмбедингах объектов. Авторегрессионная модель на основе трансформера обучается предсказывать семантические идентификаторы следующего объекта по истории взаимодействий пользователя, представленной в виде последовательности таких идентификаторов.

Ключевым преимуществом данного подхода является то, что объекты с семантически схожими описаниями получают идентификаторы с общим префиксом. Это позволяет модели обобщаться между схожими объектами через механизм разделяемых токенов и эффективно обрабатывать ситуации холодного старта, когда новые объекты могут быть закодированы по их описанию без дополнительного обучения.

2.3.3 Обобщение семантических идентификаторов в задачах ранжирования

Работа [14] исследует применение семантических идентификаторов не только в генеративном поиске, но и в классической задаче ранжирования. Авторы показывают, что замена произвольных числовых идентификаторов семантическими позволяет улучшить обобщение модели ранжирования на длиннохвостые и новые объекты. Это подтверждает универсальность концепции семантических идентификаторов и её применимость за пределами генеративного подхода.

2.4 Единый фреймворк GRID

Несмотря на активное развитие направления, сравнение различных подходов к построению семантических идентификаторов оставалось затруднённым ввиду отсутствия единой открытой реализации. Работы использовали различные экспериментальные установки, датасеты и архитектуры, что делало прямое сопоставление результатов ненадёжным.

Фреймворк GRID [6], предложенный исследователями Snap Research, является первой попыткой систематически устранить этот недостаток. GRID предоставляет модульную реализацию полного пайплайна генеративной рекомендации с семантическими идентификаторами, включающего три компонента: генерацию эмбеддингов объектов с помощью предобученных языковых моделей, обучение квантизатора (RK-Means, RVQ или RQ-VAE) для получения семантических идентификаторов, а также обучение и инференс генеративной рекомендательной модели.

Проведённые авторами эксперименты выявили ряд неочевидных закономерностей. В частности, простой метод RK-Means превосходит или сопоставим с более сложным RQ-VAE при значительно меньших вычислительных затратах. Архитектура «кодировщик–декодировщик» существенно превосходит декодер-only модели. Аугментация данных методом скользящего окна оказывает значительное влияние на итоговое качество. Все эксперименты проводились на датасетах Amazon Reviews (Beauty, Sports and Outdoors, Toys and Games) с использованием стандартного протокола оценки leave-one-out.

Вместе с тем в рамках GRID не исследуется вопрос о том, по каким внутренним характеристикам (intrinsic-метрикам) можно оценить качество полученных семантических идентификаторов независимо от конечного качества рекомендаций. Именно этот вопрос является центральным в настоящей работе.

2.5 Метрики оценки в рекомендательных системах

2.5.1 Extrinsic метрики

Стандартными метриками оценки качества рекомендательных систем в режиме ранжирования являются $\text{Recall}@K$, $\text{Precision}@K$, $\text{NDCG}@K$ и $\text{MRR}@K$.

Метрика $\text{Recall}@K$ оценивает долю релевантных объектов, попавших в список из K рекомендаций:

$$\text{Recall}@K = \frac{|\text{релевантных объектов в top-}K|}{|\text{все го релевантных объектов}|}. \quad (3)$$

Нормализованный дисконтированный накопленный выигрыш ($\text{NDCG@}K$) учитывает позицию релевантного объекта в ранжированном списке:

$$\text{NDCG@}K = \frac{\text{DCG@}K}{\text{IDCG@}K}, \quad \text{DCG@}K = \sum_{i=1}^K \frac{\text{rel}_i}{\log_2(i+1)}, \quad (4)$$

где $\text{rel}_i \in \{0, 1\}$ — релевантность объекта на позиции i , а $\text{IDCG@}K$ — идеальное значение DCG. В работах по генеративным рекомендациям [10, 6] также широко используется метрика $\text{Recall@}K$.

2.5.2 Intrinsic метрики семантических идентификаторов

В отличие от extrinsic метрик, оценивающих конечное качество рекомендаций, intrinsic метрики характеризуют свойства самих семантических идентификаторов. Хотя единого стандартного набора таких метрик в литературе не установлено, ряд работ косвенно указывает на важные свойства.

Авторы GRID [6] отмечают проблему коллизий семантических идентификаторов, когда несколько объектов получают одинаковый кортеж кодов. Для устранения коллизий предлагается добавление дополнительного разряда дедупликации. Это указывает на то, что коэффициент коллизий (Collision Rate) является значимой характеристикой квантизатора. Проблема неравномерного использования кодбука (codebook collapse) широко обсуждается в контексте VQ-моделей [9, 15] и напрямую влияет на ёмкость дискретного представления.

Гипотеза о сохранении семантической близости в пространстве кодов является ключевой мотивацией всего направления [10]: предполагается, что объекты с семантически близкими описаниями получают идентификаторы с общим префиксом. Тем не менее количественная проверка этой гипотезы в существующей литературе представлена недостаточно. Настоящая работа восполняет данный пробел, предлагая формальный набор intrinsic метрик и эмпирически исследуя их связь с итоговым качеством рекомендаций.

2.6 Выводы по главе

Проведённый обзор позволяет сформулировать следующие наблюдения, определяющие постановку настоящего исследования.

Во-первых, семантические идентификаторы стали центральным компонентом современных генеративных рекомендательных систем, и качество их построения принципиально влияет на итоговое качество рекомендаций.

Во-вторых, несмотря на наличие нескольких конкурирующих методов квантования (RK-Means, RVQ, RQ-VAE), их сравнение по внутренним свойствам полученных кодов в литературе не проводилось — оценка ограничивалась конечными метриками рекомендации.

В-третьих, гипотеза о сохранении семантической близости в пространстве дискретных кодов является теоретической основой всего подхода, однако количественная проверка этой гипотезы отсутствует.

Настоящая работа направлена на устранение указанных пробелов путём предложения набора intrinsic метрик качества семантических идентификаторов, их измерения для трёх методов квантования на стандартных датасетах Amazon Reviews, а также эмпирического анализа корреляции предложенных метрик с итоговым качеством рекомендаций.

3 Теоретические основы

В данной главе формализована постановка задачи последовательной рекомендации, введено понятие семантического идентификатора, описана математическая основа применяемых методов векторного квантования, а также определены метрики оценки качества, используемые в настоящем исследовании.

3.1 Постановка задачи

Пусть $\mathcal{U}$ — множество пользователей, $\mathcal{I}$ — множество объектов (айтемов). Каждый пользователь $u \in \mathcal{U}$ характеризуется хронологически упорядоченной последовательностью взаимодействий:

$$\mathcal{S}^u = (i_1^u, i_2^u, \dots, i_{T_u}^u), \quad i_t^u \in \mathcal{I}, \quad (5)$$

где T_u — длина последовательности пользователя u .

Задача последовательной рекомендации. Для заданного пользователя u с историей взаимодействий $\mathcal{S}^u$ требуется предсказать наиболее вероятный следующий объект $i_{T_u+1}^u$, то есть оценить условное распределение:

$$p(i_{T_u+1}^u \mid i_1^u, i_2^u, \dots, i_{T_u}^u). \quad (6)$$

В парадигме генеративной рекомендации с семантическими идентификаторами эта задача решается в два этапа. На первом этапе каждому объекту $i \in \mathcal{I}$ сопоставляется дискретный семантический идентификатор. На втором этапе авторегрессионная модель обучается порождать идентификатор следующего объекта по последовательности идентификаторов предыдущих объектов.

3.2 Семантические идентификаторы

3.2.1 Определение

Пусть каждый объект $i \in \mathcal{I}$ снабжён текстовым описанием $\mathbf{f}_i$ (название, категория, описание, цена и др.). Предобученная языковая модель $\mathcal{E}(\cdot)$ отображает описание в вещественный вектор:

$$\mathbf{h}_i = \mathcal{E}(\mathbf{f}_i) \in \mathbb{R}^d. \quad (7)$$

Определение (Семантический идентификатор). Семантическим идентификато-

ром объекта i называется кортеж дискретных кодов:

$$\text{SID}_i = (c_i^{(1)}, c_i^{(2)}, \dots, c_i^{(L)}), \quad c_i^{(l)} \in \{0, 1, \dots, W - 1\}, \quad (8)$$

где L — глубина иерархии, W — размер кодбука на каждом уровне. Кортеж SID_i получается применением обученного квантизатора $\text{Tokenizer}(\cdot): \mathbb{R}^d \rightarrow \{0, \dots, W - 1\}^L$ к эмбедингу $\mathbf{h}_i$.

3.2.2 Ключевые свойства

Семантические идентификаторы обладают рядом свойств, отличающих их от произвольных числовых идентификаторов объектов.

Иерархичность. Коды образуют дерево: объекты, разделяющие первые k уровней идентификатора, принадлежат одной семантической группе на уровне детализации k . Это позволяет модели обобщаться между объектами через разделяемые токены.

Семантическая согласованность. Предполагается, что объекты с семантически близкими описаниями получают идентификаторы с общим префиксом:

$$\text{sim}(\mathbf{h}_i, \mathbf{h}_j) \text{ велико} \Rightarrow \exists k \geq 1: c_i^{(1)} = c_j^{(1)}, \dots, c_i^{(k)} = c_j^{(k)}. \quad (9)$$

Количественная проверка этой гипотезы является одной из задач настоящей работы.

Фиксированный размер словаря. Общее число различных идентификаторов равно W^L , что значительно меньше числа объектов в промышленных системах при разумных значениях W и L .

3.3 Методы квантования

3.3.1 Векторное квантование (VQ-VAE)

Базовым методом для получения дискретных представлений является вариационный автокодировщик с векторным квантованием (VQ-VAE) [9]. Кодировщик $\text{Enc}(\cdot)$ отображает входной вектор в непрерывное скрытое представление $\mathbf{z}_e$, которое заменяется ближайшим вектором из обучаемого кодбука $\mathcal{E} = \{\mathbf{e}_k\}_{k=0}^{W-1}$:

$$\mathbf{z}_q = \mathbf{e}_{k^*}, \quad k^* = \arg \min_k \|\mathbf{z}_e - \mathbf{e}_k\|_2. \quad (10)$$

Функция потерь VQ-VAE состоит из трёх слагаемых:

$$\mathcal{L}_{\text{VQ}} = \underbrace{\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2}_{\text{реконструкция}} + \underbrace{\|\text{sg}[\mathbf{z}_e] - \mathbf{z}_q\|_2^2}_{\text{кодбук}} + \underbrace{\beta \|\mathbf{z}_e - \text{sg}[\mathbf{z}_q]\|_2^2}_{\text{commitment}}, \quad (11)$$

где $\text{sg}[\cdot]$ — операция останова градиента (stop-gradient), $\hat{\mathbf{x}}$ — выход декодера $\text{Dec}(\mathbf{z}_q)$, $\beta > 0$ — коэффициент commitment-потери.

3.3.2 Остаточное квантование (RQ)

Одноуровневый квантизатор обеспечивает лишь грубое разрешение пространства представлений. Остаточное квантование (Residual Quantization, RQ) устраняет это ограничение, последовательно квантуя остаток от предыдущего уровня [8].

Пусть $\mathbf{r}_0 = \mathbf{h}_i$. На каждом уровне $l = 1, \dots, L$:

$$c^{(l)} = \arg \min_k \|\mathbf{r}_{l-1} - \mathbf{e}_k^{(l)}\|_2, \quad (12)$$

$$\mathbf{r}_l = \mathbf{r}_{l-1} - \mathbf{e}_{c^{(l)}}^{(l)}, \quad (13)$$

где $\mathbf{e}_k^{(l)}$ — k -й вектор кодбука уровня l . Итоговый семантический идентификатор: $\text{SID}_i = (c^{(1)}, \dots, c^{(L)})$.

Приближение исходного вектора суммой выбранных кодбучных векторов:

$$\hat{\mathbf{h}}_i = \sum_{l=1}^L \mathbf{e}_{c^{(l)}}^{(l)}. \quad (14)$$

3.3.3 RQ-VAE

Метод RQ-VAE [10] объединяет остаточное квантование с архитектурой автокодировщика. Кодировщик $\text{Enc}(\cdot)$ переводит эмбединг $\mathbf{h}_i$ в промежуточное представление $\mathbf{z}$, к которому применяется процедура остаточного квантования. Декодер $\text{Dec}(\cdot)$ восстанавливает $\mathbf{h}_i$ из квантованного представления. Функция потерь:

$$\mathcal{L}_{\text{RQ-VAE}} = \|\mathbf{h}_i - \text{Dec}(\hat{\mathbf{z}})\|_2^2 + \sum_{l=1}^L \left[\|\text{sg}[\mathbf{r}_{l-1}] - \mathbf{e}_{c^{(l)}}^{(l)}\|_2^2 + \beta \|\mathbf{r}_{l-1} - \text{sg}[\mathbf{e}_{c^{(l)}}^{(l)}]\|_2^2 \right]. \quad (15)$$

3.3.4 Остаточный метод К-средних (RK-Means)

Метод RK-Means [6] является более простой альтернативой RQ-VAE: вместо нейронного автокодировщика на каждом уровне применяется алгоритм К-средних к остаточным

векторам. Центроиды кластеров l -го уровня $\{\boldsymbol{\mu}_k^{(l)}\}_{k=0}^{W-1}$ находятся минимизацией суммы квадратов отклонений остатков $\mathbf{r}_{l-1}$ от ближайшего центроида:

$$\min_{\{\boldsymbol{\mu}_k^{(l)}\}} \sum_{i \in \mathcal{I}} \|\mathbf{r}_{l-1}^{(i)} - \boldsymbol{\mu}_{c_i^{(l)}}^{(l)}\|_2^2. \quad (16)$$

Код $c_i^{(l)}$ присваивается как индекс ближайшего центроида, остаток обновляется аналогично формуле RQ. Метод не имеет обучаемых параметров декодера, что существенно упрощает обучение и снижает риск вырождения кодбука.

3.3.5 Остаточная векторная квантизация (RVQ)

Метод RVQ [15] аналогичен RQ-VAE, однако кодбуки обновляются методом экспоненциального скользящего среднего (EMA) без явного декодера. Для кода $c^{(l)}$ обновление центроида:

$$\mathbf{e}_k^{(l)} \leftarrow \gamma \mathbf{e}_k^{(l)} + (1 - \gamma) \bar{\mathbf{r}}_k^{(l)}, \quad (17)$$

где $\gamma \in (0, 1)$ — коэффициент сглаживания, $\bar{\mathbf{r}}_k^{(l)}$ — среднее остатков, назначенных коду k на шаге l .

3.4 Генеративная рекомендательная модель

Модель TIGER [10] представляет задачу последовательной рекомендации как задачу условной генерации последовательности токенов. Последовательность взаимодействий пользователя u представляется конкатенацией семантических идентификаторов объектов:

$$\mathbf{x}^u = (\text{SID}_{i_1^u}, \text{SID}_{i_2^u}, \dots, \text{SID}_{i_{T_u}^u}). \quad (18)$$

Модель на основе архитектуры трансформера типа «кодировщик–декодировщик» обучается предсказывать токены $\text{SID}_{i_{T_u+1}^u}$ авторегрессионно:

$$p(\text{SID}_{i_{T_u+1}^u} \mid \mathbf{x}^u) = \prod_{l=1}^L p(c_{i_{T_u+1}^u}^{(l)} \mid c_{i_{T_u+1}^u}^{(1)}, \dots, c_{i_{T_u+1}^u}^{(l-1)}, \mathbf{x}^u). \quad (19)$$

Обучение производится минимизацией перекрёстной энтропии по всем токенам идентификатора следующего объекта. Инференс выполняется методом лучевого поиска (beam search), при котором генерируется B наиболее вероятных последовательностей токенов, каждая из которых затем сопоставляется с объектом из каталога.

3.5 Метрики качества

3.5.1 Extrinsic метрики рекомендаций

Для оценки качества рекомендаций используется протокол leave-one-out: последний объект последовательности каждого пользователя выделяется в тестовую выборку, предпоследний — в валидационную, остальные — в обучающую.

Recall@K (в ряде работ обозначается Hit Rate@K) измеряет долю тестовых объектов, попавших в список из K рекомендаций:

$$\text{Recall@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \mathbf{1} \left[i_{T_u+1}^u \in \hat{\mathcal{I}}_K^u \right], \quad (20)$$

где $\hat{\mathcal{I}}_K^u$ — множество из K рекомендованных объектов для пользователя u .

NDCG@K учитывает позицию релевантного объекта в ранжированном списке:

$$\text{NDCG@K} = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} \frac{1}{\log_2(\text{rank}^u + 1)} \cdot \mathbf{1}[\text{rank}^u \leq K], \quad (21)$$

где rank^u — позиция объекта $i_{T_u+1}^u$ в упорядоченном по убыванию вероятности списке рекомендаций для пользователя u .

В экспериментах вычисляются значения при $K \in \{5, 10\}$.

3.5.2 Intrinsic метрики семантических идентификаторов

В отличие от extrinsic метрик, оценивающих конечный результат рекомендации, intrinsic метрики характеризуют внутренние свойства полученных семантических идентификаторов.

Коэффициент коллизий (Collision Rate, CR)

Коллизией называется ситуация, когда два различных объекта получают одинаковый семантический идентификатор:

$$CR = 1 - \frac{|\{\text{SID}_i : i \in \mathcal{I}\}|}{|\mathcal{I}|}. \quad (22)$$

$CR = 0$ означает полную уникальность идентификаторов; $CR > 0$ указывает на неразличимость части объектов с точки зрения модели, что непосредственно снижает верхнюю оценку Recall@K. Данная метрика имеет прямую теоретическую связь с качеством рекомендаций: при $CR > 0$ модель в принципе не может однозначно рекомендовать объекты,

участвующие в коллизии.

Покрывтие кодбука (Codebook Utilization, CU)

Покрывтие кодбука характеризует равномерность использования кодов на каждом уровне иерархии и определяется через нормированную энтропию распределения кодов на уровне l :

$$\tilde{H}_l = \frac{H_l}{\log_2 W}, \quad H_l = - \sum_{k=0}^{W-1} p_k^{(l)} \log_2(p_k^{(l)} + \varepsilon), \quad (23)$$

где $p_k^{(l)} = |\{i : c_i^{(l)} = k\}| / |\mathcal{I}|$ — доля объектов, получивших код k на уровне l , $\varepsilon = 10^{-12}$ — константа численной устойчивости. В качестве агрегированной метрики используется среднее по уровням:

$$CU = \frac{1}{L} \sum_{l=1}^L \tilde{H}_l. \quad (24)$$

Значение $CU = 1$ соответствует равномерному распределению кодов по всему кодбуку; вырождение кодбука (codebook collapse) проявляется в $CU \ll 1$.

Сохранение семантической близости (Semantic Similarity Preservation, SSP)

Метрика SSP количественно проверяет ключевую гипотезу семантических идентификаторов: объекты с семантически близкими описаниями должны получать идентификаторы с общим префиксом.

Для случайной выборки пар $\mathcal{P} \subset \mathcal{I}^2$, $|\mathcal{P}| = 5000$, определяются два вида сходства.

Косинусное сходство в пространстве эмбедингов:

$$s_{\text{emb}}(i, j) = \frac{h_i}{\|h_i\|} \cdot \frac{h_j}{\|h_j\|}. \quad (25)$$

Сходство семантических идентификаторов через длину общего префикса:

$$s_{\text{SID}}(i, j) = \frac{1}{L} \sum_{l=1}^L \prod_{k=1}^l \mathbf{1}[c_i^{(k)} = c_j^{(k)}]. \quad (26)$$

Произведение $\prod_{k=1}^l$ обнуляется при первом несовпадении токенов, реализуя тем самым строгую префиксную семантику: если объекты расходятся на уровне k^* , все уровни $l \geq k^*$ не вносят вклада в s_{SID} .

Метрика SSP определяется как ранговая корреляция Спирмена между двумя распре-

делениями сходств по выборке пар:

$$SSP = \rho_s \left(\left\{ s_{\text{emb}}(i, j) \right\}_{(i, j) \in \mathcal{P}}, \left\{ s_{\text{SID}}(i, j) \right\}_{(i, j) \in \mathcal{P}} \right). \quad (27)$$

Использование корреляции Спирмена обусловлено тем, что s_{SID} принимает конечное число значений $\{0, 1/L, 2/L, \dots, 1\}$, что нарушает предположение о нормальности, необходимое для корреляции Пирсона. В случае, когда все значения s_{SID} константны (вырожденный кодбук), метрика полагается равной нулю.

Предсказуемость токенов (Token Predictability Score, TPS)

Метрика TPS измеряет, насколько каждый следующий токен семантического идентификатора предсказуем по уже известным предшествующим токенам. Она отражает сложность задачи авторегрессионного декодирования для рекомендательной модели.

Для уровня l вычисляется условная энтропия токена $c^{(l)}$ при известном префиксе $(c^{(1)}, \dots, c^{(l-1)})$:

$$H(c^{(l)} | c^{(1)}, \dots, c^{(l-1)}) = - \sum_{\pi} p(\pi) \sum_{k=0}^{W-1} p(k | \pi) \log_2(p(k | \pi) + \varepsilon), \quad (28)$$

где π пробегает по всем наблюдаемым префиксам длины $l-1$, $p(\pi) = |\{i : (c_i^{(1)}, \dots, c_i^{(l-1)}) = \pi\}| / |\mathcal{I}|$ — частота префикса, $p(k | \pi)$ — условная вероятность кода k при данном префиксе.

Нормированный показатель предсказуемости на уровне l :

$$TPS_l = 1 - \frac{H(c^{(l)} | c^{(1)}, \dots, c^{(l-1)})}{\log_2 W}. \quad (29)$$

Итоговая метрика усредняется по всем уровням:

$$TPS = \frac{1}{L} \sum_{l=1}^L TPS_l. \quad (30)$$

$TPS \rightarrow 1$ означает, что токены почти полностью детерминированы предшественниками; $TPS \rightarrow 0$ означает, что токены условно равномерны. Хороший диапазон, обеспечивающий баланс между выразительностью кодового пространства и обучаемостью модели: $TPS \in [0.3, 0.7]$.

Выравнивание ближайших соседей (Nearest Neighbour Alignment, NNA)

Метрика NNA измеряет, насколько ближайшие соседи объекта в пространстве эмбеддингов сохраняют близость в пространстве семантических идентификаторов.

Для случайной подвыборки $\mathcal{S} \subset \mathcal{I}$, $|\mathcal{S}| = 5000$, определяются:

- $\text{NN}_k^{\text{emb}}(i)$ — множество k ближайших соседей объекта i по косинусному сходству в пространстве эмбеддингов;
- $\text{NN}_k^{\text{SID}}(i)$ — множество k ближайших соседей объекта i по расстоянию Хэмминга в пространстве идентификаторов:

$$d_H(i, j) = \sum_{l=1}^L \mathbf{1}[c_i^{(l)} \neq c_j^{(l)}]. \quad (31)$$

$$\text{NNA} = \left\langle \frac{|\text{NN}_k^{\text{emb}}(i) \cap \text{NN}_k^{\text{SID}}(i)|}{k} \right\rangle_{i \in \mathcal{S}}. \quad (32)$$

NNA принимает значения в $[0, 1]$; $\text{NNA} = 1$ означает полное совпадение окрестностей в двух метрических пространствах, $\text{NNA} = 0$ — полную несогласованность. В экспериментах используется $k = 10$.

Силуэтный коэффициент (Silhouette Score, Sil)

Метрика Sil оценивает связность кластеров, образованных объектами с одинаковым полным семантическим идентификатором SID_i . Для каждого объекта i вычисляется стандартный силуэтный коэффициент в пространстве эмбеддингов:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad (33)$$

где $a(i)$ — среднее косинусное расстояние до объектов своего кластера (объектов с тем же SID_i), $b(i)$ — среднее косинусное расстояние до объектов ближайшего чужого кластера. Итоговая метрика:

$$\text{Sil} = \frac{1}{|\mathcal{S}|} \sum_{i \in \mathcal{S}} s(i), \quad (34)$$

где $\mathcal{S}$ — случайная подвыборка размером до 10 000 объектов. Метрика применима при наличии не менее двух различных идентификаторов и хотя бы одной коллизии; иначе кластеры вырождаются в одиночные объекты и Sil не определён. $\text{Sil} > 0$ означает, что объекты

в среднем ближе к своему кластеру, чем к ближайшему соседнему; $Sil < 0$ свидетельствует о слабой кластерной структуре.

Полный набор intrinsic-метрик, используемых в настоящем исследовании, приведён в таблице 3.1.

Таблица 3.1: Полный набор intrinsic-метрик семантических идентификаторов

Обозначение	Полное название	Диапазон	Направление
CR	Collision Rate	$[0, 1]$	↓ лучше
CU	Codebook Utilization	$[0, 1]$	↑ лучше
SSP	Semantic Similarity Preservation	$[-1, 1]$	↑ лучше
TPS	Token Predictability Score	$[0, 1]$	$[0.3, 0.7]$ норма
NNA	Nearest Neighbour Alignment	$[0, 1]$	↑ лучше
Sil	Silhouette Score	$[-1, 1]$	↑ лучше

4 Методология

В данной главе описана экспериментальная установка настоящей работы: датасет, рекомендательная модель, методы квантования, протокол оценки, а также предложенный механизм кодирования периодичности взаимодействий.

4.1 Датасет

Эксперименты проводились на датасете Amazon Beauty — широко используемом бенчмарке для оценки последовательных рекомендательных систем. Датасет содержит историю покупок косметических товаров на платформе Amazon. После стандартной предобработки (удаление пользователей и объектов с менее чем пятью взаимодействиями) каталог насчитывает $N = 12\,101$ уникальный товар.

Текстовые описания товаров (название, категория, описание, бренд) передавались в предобученную языковую модель Flan-T5-Large для получения вещественных эмбеддингов. Эмбеддинги вычислялись однократно и использовались всеми методами квантования.

4.2 Протокол оценки

Применяется стандартный протокол leave-one-out [6]: для каждого пользователя последнее взаимодействие выделяется в тестовую выборку, предпоследнее — в валидационную, остальные используются для обучения. Итоговые extrinsic-метрики вычислялись на тестовой выборке.

4.3 Рекомендательная модель

В качестве рекомендательной модели используется TIGER [10] в реализации фреймворка GRID [6]. Модель построена на основе архитектуры T5 «кодировщик–декодировщик». Гиперпараметры модели приведены в таблице 4.1.

Входная последовательность формируется конкатенацией семантических идентификаторов объектов истории пользователя.

4.4 Методы квантования

Исследуются три метода построения семантических идентификаторов, формально описанных в разделах 3.3.2–3.3.5.

Таблица 4.1: Гиперпараметры рекомендательной модели TIGER

Параметр	Значение
Размерность модели d_{model}	128
Число голов внимания	6
Число слоёв кодировщика/декодировщика	4
Размерность FFN d_{ff}	1024
Dropout	0.15
Оптимизатор	Adam ($lr = 10^{-3}$, $\lambda = 10^{-4}$)
Размер батча	256 (аккумуляция градиентов $\times 4$)
Максимальное число шагов	1000
Максимальная длина последовательности	120
Функция потерь	CrossEntropyLoss
Инференс	Beam search
Случайное зерно	42

RKMeans (Residual K-Means). На каждом уровне l алгоритм K-средних применяется к остаточным векторам r_{l-1} . Центроиды не имеют обучаемых параметров декодера. Метод используется в качестве базового во всех группах экспериментов.

RVQ (Residual Vector Quantization). Кодбуки обновляются через экспоненциальное скользящее среднее (EMA) без явного декодера.

RQ-VAE. Нейросетевой автокодировщик с остаточным квантованием в латентном пространстве.

4.5 Структура экспериментов

Эксперименты организованы в четыре группы, объединённых единым базовым экспериментом A1 (RKMeans, $L = 3$, $W = 256$, без кодирования периодичности). Такая организация обеспечивает изолированный анализ влияния каждого фактора при фиксированных остальных. Полная структура экспериментов приведена в таблице 4.2.

4.6 Кодирование периодичности взаимодействий

Стандартный подход к построению семантических идентификаторов использует исключительно контентные признаки объекта — его текстовое описание, категорию и атрибуты — и полностью игнорирует поведенческий сигнал: как часто пользователи возвращаются к данному объекту и с какой периодичностью. Группа D исследует гипотезу о том, что включение вектора периодичности взаимодействий в процесс обучения квантизатора обогащает

Таблица 4.2: Структура экспериментов

ID	Группа	Метод	L	W	Периодичность
A1	A: метод	RKMeans	3	256	—
A2	A: метод	RVQ	3	256	—
A3	A: метод	RQ-VAE	3	256	—
B1	B: глубина L	RKMeans	2	256	—
A1	B: глубина L	RKMeans	3	256	—
B2	B: глубина L	RKMeans	4	256	—
C1	C: ширина W	RKMeans	3	128	—
A1	C: ширина W	RKMeans	3	256	—
C2	C: ширина W	RKMeans	3	512	—
A1	D: периодичность	RKMeans	3	256	—
D2	D: периодичность	RKMeans	3	256	interval
D3	D: периодичность	RKMeans	3	256	topk_pos
D4	D: периодичность	RKMeans	3	256	binary_bag

структуру семантических идентификаторов поведенческим сигналом и тем самым улучшает качество рекомендаций.

Механизм кодирования. Для каждого объекта $i \in \mathcal{I}$ по всей обучающей выборке собирается список временных меток взаимодействий $\mathcal{T}_i = \{t_1^{(i)}, t_2^{(i)}, \dots\}$. На основе $\mathcal{T}_i$ строится вектор признаков периодичности $r_i \in \mathbb{R}^{d_r}$, описывающий статистику повторных взаимодействий. Вектор конкатенируется с семантическим эмбедингом объекта перед обучением квантизатора:

$$e'_i = [e_i \parallel r_i] \in \mathbb{R}^{d+d_r}, \quad (35)$$

где $e_i \in \mathbb{R}^d$ — исходный эмбединг от Flan-T5-Large. Квантизатор обучается на расширенных векторах e'_i и, следовательно, при разбиении объектов на кластеры учитывает как семантическую близость, так и поведенческое сходство. На этапе инференса рекомендательной модели TIGER эмбединги e'_i не используются: модель оперирует исключительно уже полученными семантическими идентификаторами $\text{SID}_i = (c_i^{(1)}, \dots, c_i^{(L)})$. Таким образом, поведенческий сигнал влияет лишь на структуру кодового пространства, но не изменяет архитектуру или обучение рекомендательной модели.

Стратегии формирования r_i . Исследуются три стратегии, различающиеся по типу извлекаемого поведенческого сигнала:

- **interval** ($d_r = 5$). Вектор r_i содержит агрегированные статистики интервалов между последовательными взаимодействиями с объектом i : $[count, mean, std, min, max]$, где $count$ — общее число взаимодействий, а остальные компоненты характеризуют распре-

деление временных промежутков $\Delta t_k = t_{k+1}^{(i)} - t_k^{(i)}$. Стратегия кодирует ритмичность спроса на объект: товары с регулярными повторными покупками получают малое *std* и характерное *mean*, тогда как импульсные покупки — большое *std* и *max*.

- **topk_pos** ($d_r = 5$). Вектор r_i составлен из нормированных временных позиций пяти последних взаимодействий с объектом i : $r_i = [t_{-5}^{(i)}/T, t_{-4}^{(i)}/T, \dots, t_{-1}^{(i)}/T]$, где T — длина всего временного горизонта обучающей выборки. Если объект имеет менее пяти взаимодействий, недостающие позиции заполняются нулями. Стратегия акцентирует недавность взаимодействий: объекты с высокой активностью в конце временного окна получают значения, сосредоточенные у единицы.
- **binary_bag** ($d_r = 10$). Временной горизонт обучающей выборки делится на 10 равных бинов. Компонента $r_i^{(b)} = 1$, если в бине b зафиксировано хотя бы одно взаимодействие с объектом i , и $r_i^{(b)} = 0$ иначе. Стратегия кодирует долгосрочный профиль активности: объекты с устойчивым спросом на протяжении всего периода получают вектор, близкий к единичному, тогда как сезонные или трендовые товары — разреженный вектор с ненулевыми компонентами в определённых бинах.

Все три стратегии реализованы как предобработка перед обучением квантизатора и не требуют изменений в архитектуре рекомендательной модели. Компоненты r_i нормируются до диапазона $[0, 1]$ по всему каталогу объектов перед конкатенацией.

5 Результаты экспериментов

В данной главе представлены результаты экспериментов в соответствии со структурой, описанной в главе 4. Для каждой группы сначала приводятся intrinsic-метрики семантических идентификаторов, затем extrinsic-метрики рекомендаций; результаты обсуждаются совместно.

5.1 Группа А: сравнение методов квантования

Группа А позволяет сравнить три метода квантования — RKMeans (A1), RVQ (A2) и RQ-VAE (A3) — при фиксированных $L = 3$, $W = 256$. Результаты приведены в таблице 5.1.

Intrinsic-метрики. RQ-VAE достигает наименьшего коэффициента коллизий ($CR = 0.0531$) и наибольшего значения SSP ($SSP = 0.1727$). Последнее указывает на то, что нейросетевая

Таблица 5.1: Результаты группы А: сравнение методов квантования ($L = 3$, $W = 256$)

ID	Метод	CR↓	CU↑	SSP↑	TPS↑	NNA↑	Sil↑	R@5↑	R@10↑	NDCG@10↑
A1	RKMeans	0.1196	0.9302	0.1373	0.4470	0.2170	0.0281	0.0307	0.0476	0.0249
A2	RVQ	0.1435	0.8280	0.1179	0.4487	0.1956	0.0168	0.0294	0.0467	0.0242
A3	RQ-VAE	0.0531	0.9146	0.1727	0.4399	0.0981	−0.0003	0.0284	0.0447	0.0229

оптимизация потерь реконструкции явно стимулирует сохранение семантической близости в пространстве кодов. Вместе с тем RQ-VAE демонстрирует наименьшее выравнивание ближайших соседей ($NNA = 0.0981$) и отрицательный силуэтный коэффициент ($Sil = -0.0003$), что свидетельствует о слабой кластерной структуре первого уровня кодового дерева.

RVQ, в свою очередь, показывает наихудшее покрытие кода (CU = 0.8280), тогда как у RKMeans этот показатель выше (CU = 0.9302). Значения TPS у всех трёх методов близки (0.440–0.449), что говорит о схожей глубине иерархических разбиений при данной конфигурации $L = 3$.

Extrinsic-метрики. RKMeans занимает первое место по всем четырём extrinsic-метрикам: Recall@10 = 0.0476, NDCG@10 = 0.0249. RVQ уступает базовому методу незначительно (−1.9% по Recall@10), тогда как RQ-VAE демонстрирует более заметное снижение (−6.1% по Recall@10).

Таким образом, RQ-VAE достигает лучших значений CR и SSP, однако это не транслируется в превосходство по extrinsic-метрикам. Данный результат согласуется с выводами GRID [6]: более сложный метод квантования не гарантирует улучшения конечного качества рекомендаций. Нейросетевой декодер RQ-VAE, по всей видимости, вносит дополнительный шум в кластерную структуру первого уровня, что отражается в низком NNA и отрицательном Sil. Напротив, RKMeans, не имея обучаемых параметров декодера, формирует более компактные и геометрически правильные кластеры (высокие NNA и Sil), что обеспечивает лучшую обучаемость рекомендательной модели.

5.2 Группа В: глубина кодового дерева L

Эксперименты B1 ($L = 2$), A1 ($L = 3$) и B2 ($L = 4$) варьируют глубину иерархии при фиксированных методе RKMeans и $W = 256$. Результаты приведены в таблице 5.2.

Противоречие между intrinsic- и extrinsic-метриками. Ключевое наблюдение группы В состоит в том, что монотонное улучшение intrinsic-метрик с ростом L не сопровождается соответствующим улучшением качества рекомендаций. При $L = 4$ достигаются наилучшие

Таблица 5.2: Результаты групп В и С

ID	L	CR↓	CU↑	SSP↑	TPS↑	NNA↑	Sil↑	R@10↑	NDCG@10↑
B1	2	0.3588	0.9661	0.0684	0.2112	0.1080	-0.0493	0.0394	0.0200
A1	3	0.1196	0.9302	0.1373	0.4470	0.2170	0.0281	0.0476	0.0249
B2	4	0.0468	0.9287	0.1242	0.5795	0.2421	0.0195	0.0417	0.0217

значения CR (0.0468), TPS (0.5795) и NNA (0.2421), тогда как Recall@10 (0.0417) и NDCG@10 (0.0217) уступают базовому уровню $L = 3$ на 12.4% и 12.9% соответственно. Эта диссоциация указывает на то, что intrinsic-метрики характеризуют разные аспекты кодового пространства и ни одна из них в отдельности не является надёжным показателем extrinsic-качества.

Нижняя граница: недостаточная ёмкость при $L = 2$. При $L = 2$ пространство кодов содержит лишь $256^2 = 65\,536$ различных кортежей для $N = 12\,101$ объектов. Несмотря на формальную достаточность ёмкости, квантизатор не обеспечивает равномерного заполнения: CR = 0.3588 означает, что 35.9% объектов каталога разделяют идентификатор хотя бы с одним другим объектом. Это создаёт жёсткое структурное ограничение: рекомендательная модель принципиально не способна однозначно адресовать коллидирующие объекты, что непосредственно занижает верхнюю оценку Recall@K. Помимо этого, отрицательный силуэтный коэффициент (Sil = -0.0493) свидетельствует о том, что при двух уровнях кластеры первого уровня имеют избыточный охват и не соответствуют реальной семантической структуре каталога.

Верхняя граница: затруднение обучения при $L = 4$. При $L = 4$ декодируемый кортеж удлиняется до четырёх токенов, что при фиксированном числе шагов обучения (1000) и фиксированном размере батча приводит к недостаточной сходимости авторегрессионной модели. Иными словами, при $L = 4$ ёмкость кодового пространства ($256^4 \approx 4,3 \cdot 10^9$) существенно превышает потребности каталога из 12 101 объектов, однако рекомендательная модель не успевает надёжно выучить распределение по расширенному дереву за отведённое число шагов.

Вывод: $L = 3$ как оптимальный баланс для данной установки. Совокупность наблюдений указывает на то, что оптимальная глубина определяется не только геометрическими свойствами кодового пространства, но и вычислительным бюджетом обучения рекомендательной модели. При планировании экспериментов рекомендуется выбирать L из условия $W^L \gg N$ (достаточная ёмкость для избежания коллизий) при одновременном контроле длины декодируемой последовательности: увеличение L оправдано лишь при пропорциональном

увеличении числа шагов обучения. Для Amazon Beauty ($N \approx 1.2 \cdot 10^4$) при 1000 шагах обучения конфигурация $L = 3$, $W = 256$ обеспечивает наилучший баланс.

5.3 Группа C: ширина кодбука W

Эксперименты C1 ($W = 128$), A1 ($W = 256$) и C2 ($W = 512$) варьируют размер кодбука при $L = 3$ и методе RKMeans. Результаты приведены в таблице 5.3.

Таблица 5.3: Результаты группы C: влияние ширины кодбука W (метод RKMeans, $L = 3$)

ID	W	CR↓	CU↑	SSP↑	TPS↑	NNA↑	Sil↑	R@10↑	NDCG@10↑
C1	128	0.1845	0.9561	0.1679	0.3773	0.2393	0.0156	0.0481	0.0247
A1	256	0.1196	0.9302	0.1373	0.4470	0.2170	0.0281	0.0476	0.0249
C2	512	0.0757	0.8978	0.0925	0.5041	0.1803	0.0270	0.0390	0.0208

Противоречие между ёмкостью кодового пространства и extrinsic-качеством. Группа C обнаруживает закономерность, симметричную наблюдению группы B: монотонное улучшение CR с ростом W ($0.185 \rightarrow 0.120 \rightarrow 0.076$) не транслируется в улучшение качества рекомендаций. Наилучший Recall@10 (0.0481) достигается при наименьшем $W = 128$, тогда как $W = 512$ уступает базовому уровню на 18.1% по Recall@10 и на 16.5% по NDCG@10.

Разреженность кодбука при $W = 512$. Фундаментальная причина деградации при $W = 512$ состоит в несоответствии между ёмкостью кодового пространства и размером каталога. При $L = 3$ и $W = 512$ теоретически различимы $512^3 \approx 1.3 \cdot 10^8$ кортежей, тогда как каталог содержит лишь $N = 12\,101$ объект. Вследствие этого кодбук заполняется крайне неравномерно, что подтверждается снижением CU до 0.898: значительная часть кодов остаётся незадействованной. Разреженное кодовое пространство затрудняет обобщение рекомендательной модели через разделяемые токены — механизм, на котором основана ключевая идея TIGER [10]: при $W = 512$ объекты, принадлежащие одной семантической группе, с меньшей вероятностью разделяют общий префикс, чем при $W = 128$.

Преимущество компактного кодбука при $W = 128$. При $W = 128$ квантизатор вынужден отображать 12 101 объект в пространство $128^3 \approx 2.1 \cdot 10^6$ кортежей, что приводит к более плотной и равномерной укладке объектов в кодовом дереве. Это подтверждается максимальным значением CU (0.9561) и NNA (0.2393): ближайшие соседи в пространстве эмбедингов чаще оказываются соседями и в пространстве кодов. Компактный словарь из 128 токенов на уровень позволяет рекомендательной модели быстрее выучить распределение

токенов при фиксированном бюджете обучения (1000 шагов), что и обуславливает лучший Recall@10. Вместе с тем рост CR до 0.185 означает, что 18.5% объектов участвуют в коллизиях, устанавливая структурный потолок для дальнейшего улучшения Recall@K.

Вывод: W определяется соотношением N и бюджета обучения. Совокупность результатов групп В и С позволяет сформулировать общий принцип: оптимальные L и W определяются не только размером каталога N , но и числом шагов обучения рекомендательной модели. При фиксированном бюджете следует выбирать W таким образом, чтобы заполненность кодбука (CU) была близка к единице, а CR оставался приемлемо малым. Для Amazon Beauty ($N \approx 1.2 \cdot 10^4$, 1000 шагов) это условие наилучшим образом выполняется при $W \in \{128, 256\}$; при увеличении N или бюджета обучения оптимальное W должно пересматриваться.

5.4 Группа D: кодирование периодичности взаимодействий

Группа D исследует гипотезу о том, что включение поведенческого сигнала периодичности в процесс квантования (раздел 4.6) улучшает качество семантических идентификаторов. Базовый эксперимент — A1 (без периодичности). Результаты приведены в таблице 5.4.

Таблица 5.4: Результаты группы D: стратегии кодирования периодичности

ID	Стратегия	CR↓	CU↑	SSP↑	TPS↑	NNA↑	Sil↑	R@10↑	NDCG@10↑
A1	—	0.1196	0.9302	0.1373	0.4470	0.2170	0.0281	0.0476	0.0249
D2	interval	0.0563	0.9387	0.0998	0.4400	0.1624	0.0069	0.0443	0.0229
D3	topk_pos	0.0513	0.9384	0.1157	0.4396	0.1560	0.0039	0.0381	0.0207
D4	binary_bag	0.0976	0.9398	0.1198	0.4440	0.2482	0.0188	0.0349	0.0185

Влияние на intrinsic-метрики. Все три стратегии снижают CR относительно базового уровня: D3 достигает минимального CR = 0.0513. Покрытие кодбука CU незначительно возрастает у D2 и D3, что указывает на более равномерное распределение кодов при обогащении эмбеддингов.

Однако все стратегии демонстрируют снижение SSP по сравнению с A1: наименьшее — у D4 (SSP = 0.1198), наибольшее — у D2 (SSP = 0.0998). Это означает, что добавление поведенческого вектора ослабляет сохранение чисто семантической близости в кодовом пространстве: квантизатор вынужден одновременно учитывать семантику описаний и паттерны взаимодействий, что приводит к компромиссу. NNA снижается у D2 и D3 относительно базового, тогда как D4 (binary_bag) сохраняет высокое выравнивание ближайших соседей (NNA = 0.2482). Силуэтный коэффициент у всех стратегий ниже базового уровня.

Влияние на extrinsic-метрики. Ни одна из стратегий кодирования периодичности не улучшает extrinsic-метрики относительно базового уровня A1. Снижение Recall@10 составляет 6.9% для D2, 19.9% для D3 и 26.7% для D4. Наибольшее ухудшение демонстрирует стратегия `binary_bag`, несмотря на наилучшее значение NNA в данной группе.

Интерпретация состоит в следующем. Поведенческий вектор r_i , добавляемый к эмбедингу до квантования, направляет квантизатор на разделение объектов по паттернам взаимодействий, а не по семантике контента. Это создаёт идентификаторы, структура которых частично отражает поведенческие паттерны, но хуже согласована с семантическим пространством, в котором обучается рекомендательная модель. В результате TIGER обнаруживает разрыв между семантической близостью, закодированной в идентификаторах, и реальной семантикой объектов, что ухудшает авторегрессионное декодирование.

Гипотеза об обогащении семантических идентификаторов поведенческим сигналом таким образом **не подтверждается** в рамках рассмотренных стратегий. Полученные результаты свидетельствуют о необходимости более тонкой интеграции поведенческого сигнала — например, в виде дополнительного члена в функции потерь рекомендательной модели, а не посредством модификации входных векторов квантизатора.

5.5 Корреляционный анализ intrinsic и extrinsic метрик

На основе экспериментов вычислены попарные корреляции Пирсона (r) и Спирмена (ρ) между всеми intrinsic-метриками (CR, CU, SSP, TPS, NNA, Sil) и всеми extrinsic-метриками (Recall@5, Recall@10, NDCG@5, NDCG@10). Матрицы корреляций приведены в таблицах 5.5 и 5.6.

Таблица 5.5: Корреляции Пирсона (r) между intrinsic и extrinsic метриками ($n = 10$)

Intrinsic	NDCG@5	NDCG@10	Recall@5	Recall@10
CR	−0.066	−0.068	+0.096	+0.036
CU	−0.297	−0.307	−0.239	−0.262
SSP	+0.546	+0.555	+0.541	+0.541
TPS	+0.095	+0.113	−0.060	+0.016
NNA	+0.115	+0.119	+0.029	+0.062
Sil	+0.372	+0.334	+0.226	+0.220

5.5.1 Существование монотонной связи

Наиболее выраженную и устойчивую связь с extrinsic-метриками демонстрирует SSP. Корреляции Пирсона составляют $r \in [0.541, 0.555]$ по всем четырём extrinsic-метрикам; кор-

Таблица 5.6: Корреляции Спирмена (ρ) между intrinsic и extrinsic метриками ($n = 10$)

Intrinsic	NDCG@5	NDCG@10	Recall@5	Recall@10
CR	+0.236	+0.182	+0.401	+0.358
CU	-0.321	-0.298	-0.213	-0.127
SSP	+0.503	+0.559	+0.480	+0.564
TPS	+0.030	+0.134	-0.024	-0.055
NNA	-0.042	+0.097	-0.012	+0.042
Sil	+0.224	+0.286	+0.158	+0.091

реляции Спирмена — $\rho \in [0.480, 0.564]$. Среднее $|r|$ по всем парам для SSP равно 0.546, $|\rho| = 0.527$ — наибольшее среди всех шести intrinsic-метрик.

Метрики TPS и NNA практически не коррелируют с extrinsic-качеством ($|r| < 0.12$, $|\rho| < 0.13$). Метрика CU демонстрирует умеренную отрицательную корреляцию: более высокое покрытие кодбука ассоциировано с более низким extrinsic-качеством ($r \approx -0.28$ по Пирсону). Данный эффект объясняется конфаундером: при малом W или малом L (эксперименты B1, C1) кодбук заполняется полнее, но объём пространства кодов недостаточен для чёткого разделения объектов. Метрика Sil показывает умеренно положительную корреляцию с NDCG@5 ($r = 0.372$), однако менее выраженную, чем SSP.

5.5.2 Наилучшие предикторы extrinsic-качества

Сводная таблица предиктивной силы intrinsic-метрик приведена в таблице 5.7.

Таблица 5.7: Предиктивная сила intrinsic-метрик (среднее $|r|$ и $|\rho|$ по четырём extrinsic-метрикам)

Intrinsic	Ср. $ r $ Пирсон	Ср. $ \rho $ Спирмен	Направление
SSP	0.546	0.527	+
Sil	0.288	0.190	+
CU	0.276	0.240	—
NNA	0.081	0.049	нет
TPS	0.071	0.061	нет
CR	0.067	0.294	нет

SSP является наилучшим предиктором extrinsic-качества среди всех шести рассмотренных intrinsic-метрик. Результат содержательно интерпретируем: SSP напрямую измеряет, в какой мере семантическая близость объектов в пространстве эмбедингов сохраняется в иерархии кодов. Если квантизатор нарушает семантическую структуру, рекомендательная модель получает идентификаторы, в которых похожие объекты расположены в разных поддеревьях — это ухудшает обобщение через разделяемые токены и снижает качество beam search.

Метрика Sil имеет умеренную предиктивную силу ($|\overline{r}| = 0.288$), однако ниже, чем у SSP. CU, несмотря на ненулевую среднюю корреляцию, имеет отрицательное направление: высокий CU в данной выборке коинцидирует с конфигурациями с малым W или малым L , неблагоприятными для extrinsic-качества. TPS и NNA не обладают предиктивной силой в рамках данной выборки.

Практическое значение. Положительная корреляция SSP с extrinsic-метриками означает, что данная метрика может служить прокси-критерием при первоначальном отборе конфигураций квантизатора. Расчёт SSP не требует обучения рекомендательной модели и занимает значительно меньше вычислительных ресурсов: для $n = 10$ экспериментов измерение SSP может сократить объём полного обучения с нуля в случаях, когда несколько конфигураций заведомо уступают по SSP.

6 Заключение

6.1 Основные результаты

В настоящей работе проведено систематическое исследование свойств семантических идентификаторов в генеративных рекомендательных системах на примере датасета Amazon Beauty и модели TIGER. Достигнуты следующие результаты.

1. Система intrinsic-метрик. Предложен и формально обоснован набор из шести intrinsic-метрик качества семантических идентификаторов: Collision Rate (CR), Codebook Utilization (CU), Semantic Structure Preservation (SSP), Tree Path Similarity (TPS), Nearest Neighbour Alignment (NNA) и Silhouette Score (Sil). Метрики охватывают различные аспекты качества кодового пространства: уникальность идентификаторов, равномерность использования кодабука, сохранение семантической близости и связность кластеров.

2. Сравнение методов квантования. Базовый метод RKMeans превосходит RVQ и RQ-VAE по всем extrinsic-метрикам при идентичных L и W . RQ-VAE достигает наименьшего CR и наибольшего SSP за счёт нейросетевой оптимизации реконструкции, однако это не компенсирует ухудшение кластерной структуры первого уровня (отрицательный Sil, низкий NNA). Данный результат подтверждает наблюдение GRID [6] о конкурентоспособности более простых методов.

3. Влияние гиперпараметров. Оптимальное соотношение глубины и ширины кодового дерева для датасета Amazon Beauty при числе шагов обучения 1000 составляет $L = 3$, $W = 256$. Увеличение L до 4 улучшает CR и TPS, но снижает Recall@10 на 12.4% из-за затруднения обучения на более длинных кортежах. Уменьшение W до 128 неожиданно улучшает Recall@10 на 1.1% относительно базового уровня благодаря более компактному словарю, однако сопровождается ростом CR.

4. Кодирование периодичности. Ни одна из трёх стратегий включения поведенческого вектора (interval, topk_pos, binary_bag) не улучшила extrinsic-метрики. Все стратегии снижают Recall@10 на 6.9–26.7%. Поведенческий сигнал, интегрированный непосредственно в эмбединг до квантования, создаёт разрыв между семантической структурой идентификаторов и обучающим сигналом рекомендательной модели.

5. Корреляционный анализ. SSP является наилучшим предиктором extrinsic-качества среди всех рассмотренных intrinsic-метрик (среднее $|r| = 0.546$, $|\rho| = 0.527$ по Пирсону и Спирмену соответственно). Метрики TPS и NNA не проявили предиктивной силы в данной экспериментальной установке.

6.2 Практические рекомендации

На основе полученных результатов сформулированы следующие рекомендации по выбору конфигурации квантизатора для генеративных рекомендательных систем.

При ограниченном вычислительном бюджете целесообразно использовать RKMeans как метод квантования: он обеспечивает сравнимое или превосходящее качество рекомендаций при значительно меньших вычислительных затратах по сравнению с RQ-VAE. Для первоначального отбора конфигурации рекомендуется вычислять SSP: высокое значение этой метрики ассоциировано с лучшим extrinsic-качеством и не требует полного цикла обучения рекомендательной модели. При выборе L и W следует учитывать число уникальных объектов каталога N и число шагов обучения: при малом N ($\sim 10^4$) и умеренном числе шагов ($\sim 10^3$) конфигурация $L = 3$, $W = 256$ обеспечивает баланс между выразительностью кодового пространства и эффективностью обучения.

6.3 Ограничения и направления дальнейших исследований

Настоящее исследование имеет ряд ограничений. Во-первых, все эксперименты проводились на одном датасете (Amazon Beauty), что ограничивает обобщаемость выводов. Расширение экспериментальной базы на датасеты Sports and Outdoors и Toys and Games (также входящие в Amazon Reviews) позволит проверить устойчивость выявленных закономерностей.

Во-вторых, исследование гипотезы о кодировании периодичности ограничено тремя стратегиями. Перспективным направлением является интеграция поведенческого сигнала через дополнительный член в функции потерь рекомендательной модели вместо модификации входных векторов квантизатора.

Наконец, предложенная система intrinsic-метрик может быть применена к другим методам дискретного кодирования (например, к методам на основе графовых нейронных сетей или к иерархической кластеризации), что открывает возможность для более широкого сравнительного анализа.

Список литературы

- [1] Jiaxin Deng, Shiyao Wang, Kuo Cai, Lejian Ren, Qigen Hu, Weifeng Ding, Qiang Luo и Guorui Zhou. “Onerec: Unifying retrieve and rank with generative recommender and iterative preference alignment”. В: *arXiv preprint arXiv:2502.18965* (2025).
- [2] Shijie Geng, Shuchang Liu, Zuohui Fu, Yingqiang Ge и Yongfeng Zhang. “Recommendation as Language Processing (RLP): A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5)”. В: *Proceedings of the 16th ACM Conference on Recommender Systems (RecSys)*. 2022, с. 299—315.
- [3] Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, YongDong Zhang и Meng Wang. “LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation”. В: *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2020, с. 639—648.
- [4] Xiangnan He, Lizi Liao, Hanwang Zhang, Liqiang Nie, Xia Hu и Tat-Seng Chua. “Neural Collaborative Filtering”. В: *Proceedings of the 26th International Conference on World Wide Web (WWW)*. 2017, с. 173—182.
- [5] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas и Domonkos Tikk. “Session-based Recommendations with Recurrent Neural Networks”. В: *Proceedings of the 4th International Conference on Learning Representations (ICLR)*. 2016.
- [6] Clark Mingxuan Ju, Liam Collins, Leonardo Neves, Bhuvesh Kumar, Louis Yufeng Wang, Tong Zhao и Neil Shah. “Generative Recommendation with Semantic IDs: A Practitioner’s Handbook”. В: *Proceedings of the 34th ACM International Conference on Information and Knowledge Management (CIKM)*. 2025.
- [7] Wang-Cheng Kang и Julian McAuley. “Self-Attentive Sequential Recommendation”. В: *Proceedings of the IEEE International Conference on Data Mining (ICDM)*. SASRec. 2018, с. 197—206.
- [8] Doyup Lee, Chiheon Kim, Saehoon Kim, Minsu Cho и Wook-Shin Han. “Autoregressive Image Generation using Residual Quantization”. В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. RQ-VAE. 2022, с. 11523—11532.
- [9] Aaron van den Oord, Oriol Vinyals и Koray Kavukcuoglu. “Neural Discrete Representation Learning”. В: *Advances in Neural Information Processing Systems*. Т. 30. VQ-VAE. 2017.
- [10] Shashank Rajput, Nikhil Mehta и Anima Singh. “Recommender Systems with Generative Retrieval”. В: *arXiv preprint, arXiv:2305.05065* (2023).

- [11] Steffen Rendle, Christoph Freudenthaler и Lars Schmidt-Thieme. “Factorizing Personalized Markov Chains for Next-Basket Recommendation”. B: *Proceedings of the 19th International Conference on World Wide Web (WWW)*. 2010, с. 811—820.
- [12] J. Ben Schafer, Joseph A. Konstan и John Riedl. “Recommender Systems in E-Commerce”. B: *Proceedings of the 1st ACM Conference on Electronic Commerce* (1999), с. 158—166.
- [13] Andrew I. Schein, Alexandrin Popescul, Lyle H. Ungar и David M. Pennock. “Methods and Metrics for Cold-Start Recommendations”. B: *Proceedings of the 25th Annual International ACM SIGIR Conference*. 2002, с. 253—260.
- [14] Anima Singh, Trung Vu, Nikhil Mehta, Raghunandan Keshavan, Maheswaran Sathiamoorthy, Yilin Zheng, Lichan Hong, Lukasz Heldt, Li Wei, Devansh Tandon, Ed H. Chi и Xinyang Yi. “Better Generalization with Semantic IDs: A Case Study in Ranking for Recommendations”. B: *arXiv preprint, arXiv:2306.08121* (2023).
- [15] Neil Zeghidour, Alejandro Luebs, Ahmed Omran, Jan Skoglund и Marco Tagliasacchi. “SoundStream: An End-to-End Neural Audio Codec”. B: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 30 (2021). RVQ / Residual Vector Quantization, с. 495—507.

Приложение

Использование ИИ При написании дипломной работы были использованы инструменты на базе ИИ для языкового редактирования и улучшения читаемости текста, а также ускорения поиска релевантной информации. Однако все исследовательские идеи, методологический подход, анализ и основной контент разработаны автором самостоятельно.